Naturlige eksperimenter

Erik Gahner Larsen

Kausalanalyse i offentlig politik

Dagsorden

- Eksperimenter og naturlige eksperimenter
- Naturlige eksperimenter
 - Styrker og svagheder
 - Eksempler
 - ► Tre typer: RDD, IV, DID

Forrige gang

- Eksperimenter
 - Laboratorieeksperimenter
 - Spørgeskemaeksperimenter
 - Felteksperimenter
- ► Fælles for disse eksperimenter: forskeren står for interventionen
- Kontrol med randomiseringen og implementeringen af stimuli

I dag: Naturlige eksperimenter

- Naturlige eksperimenter: når "naturen" står for randomiseringen
 - ▶ (≠ forskeren)
- Forskellen på naturlige eksperimenter og "rigtige" eksperimenter
 - "However, unlike true experiments, the data used in natural experiments come from"naturally" occurring phenomena actually, in the social sciences, from phenomena that are often the product of social and political forces. Because the manipulation of treatment variables is not generally under the control of the analyst, natural experiments are, in fact, observational studies." (Dunning 2012, 16)

Naturlige eksperimenter

- ► Naturlige eksperimenter bygger på som alle studier bestemte antagelser omkring datagenerationsprocessen
- ▶ Nogle empiriske fænomener er mere eksogene end andre
 - Offentlige politikker er sjældent eksogene, men nøje planlagt
 - ▶ Naturkatastrofer, terrorangreb og lignende er ofte eksogene
 - "Katrina was an act of nature that was close to what a political scientist would have liked to have done if he or she could intervening and changing the political makeup of several large U.S. cities such as New Orleans, Houston, and Atlanta." (Morton og Williams 2010, 53)

Naturlige eksperimenter

- Vi udnytter at naturen foretager randomiseringen
- Randomiseringen skaber eksogenitet
 - 'As-if' randomisering
- Ikke et spørgsmål om randomisering eller ej
 - Plausibilitet på et kontinuum (Dunning 2008)
 - Mindst plausibel as-if randomisering: observationsstudier
 - Mest plausibel as-if randomisering: eksperimenter
- Naturlige eksperimenter ligger et sted mellem observationsstudier og eksperimenter
- I de bedste tilfælde: Stærk kausal inferens i den "rigtige" verden (ligesom felteksperimenter)

Hvad er forskellen på kvasieksperimenter og naturlige eksperimenter?

Kvasieksperimenter: "[har] det til fælles med naturlige eksperimenter, at den eksperimentelle intervention kommer udefra. Den er ikke manipuleret af forskeren, men tilvejebragt af naturen eller det politiske system. Men til forskel fra andre eksperimenter er inddelingen i eksperiment- og kontrolgrupper ikke randomiseret. Grupperne kan derfor være forskellige på mange andre parametre end deres udsættelse for den eksperimentelle intervention." (Blom-Hansen og Serritzlew 2014, 18)

Eksempel: Effekten af nationale tests

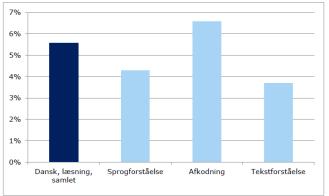
- ► Spørgsmål: Påvirker nationale tests elevers efterfølgende tests?
- Udfordring: Svært at finde tilfældig variation
- ► Løsning: Lav et eksperiment hvor det bliver randomiseret, om man får en national test eller ej
- Alternativ løsning: Udnyt eksogen variation i, hvem der får nationale tests

Eksempel: Effekten af nationale tests

- ▶ Rambøll (2013): Evaluering af de nationale tests i folkeskolen
- "Til førstnævnte analyser af elev- og skoleniveau udnyttes det, at it-systemet brød sammen i en periode på ni dage fra den 2. til 10. marts 2010. Det betød, at de elever, der skulle have gennemført en test på det tidspunkt, slet ikke fik nogen test. Ved at sammenligne disse elevers resultater ved efterfølgende nationale test, med resultaterne for alle de andre elever, der gennemførte testen i 2010, kan effekten af de nationale test undersøges."
- ► "Denne analyse bekræfter antagelsen, at det var tilfældigt, hvilke elever der blev ramt af nedbrud. Således har vi et grundlag for at lave en robust analyse af forskelle i faglige resultater mellem elevernes faglige resultater og kan tillægge eventuelle forskelle deres deltagelse i de nationale test."

Eksempel: Effekten af nationale tests

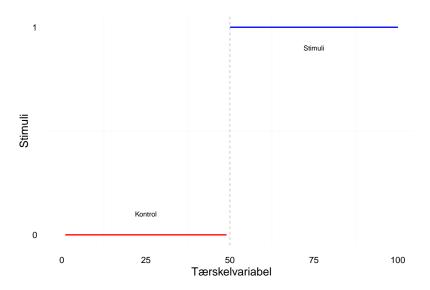




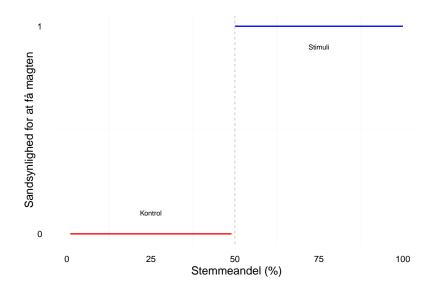
Regressionsdiskontinuitetsdesignet

- Identifikationsstrategi hvor vi udnytter viden omkring processen der inddeler observationer i stimuli og kontrolgrupper på baggrund af en (eller flere) kontinuerlige (tærskel)variable
- ► Tre elementer: Tærskelvariabel, tærskelværdi, udfaldsvariabel
- Enheder der har en værdi over (/under) tærskelværdien bliver tildelt stimuli (/kontrol)
 - Stimulitildeling er en deterministisk funktion af en tærskelvariabel (ikke randomisering)
 - ► Men 'as-if' tilfældigt i et vindue omkring tærskelværdien
- Stimulieffekten: Forskellen i udfaldsvariablen for enheder der ligger lige over tærskelværdien og enheder der ligger lige under tærskelværdien
- ▶ Introduktion: Olsen (2014): Tærskelvariable og tærskelværdier: en introduktion til regressions-diskontinuitetsdesignet

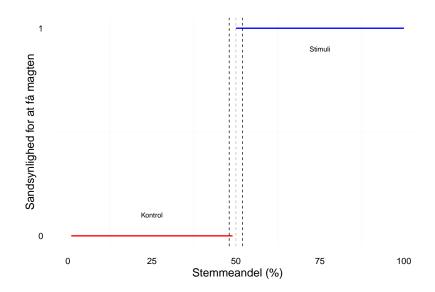
Tærskelvariabel



Eksempel: Stemmeandel i et topartisystem



Eksempel: Stemmeandel i et topartisystem



Fra stimulitildeling til stimulieffekt

- Vi kender mekanismen bag stimulitildelingen
 - "In a regression-discontinuity design, treatment assignment is determined by the value of a covariate, sometimes called a forcing variable, and there is a sharp discontinuity in the probability of receiving treatment at a particular threshold value of this covariate" (Dunning 2012, 64)
 - Distinktion mellem 'sharp' og 'fuzzy' RDD
 - ► Forkerte estimater hvis enheder kan manipulere stimulitildeling (Lee og Lemieux 2010, 283)
- ▶ På baggrund af denne stimulitildeling kan vi estimere effekten af at have modtaget stimuli, forudsat at:
 - Stimuli og kontrol ikke afviger på andre forhold end 'as-if' tilfældig stimulitildeling
- ► Tærskelvariablen og udfaldsvariablen vil ofte korrelere, hvorfor vi blot indskrænker os til at kigge på diskontiniuteten

RDD og Campbells kausalmodel

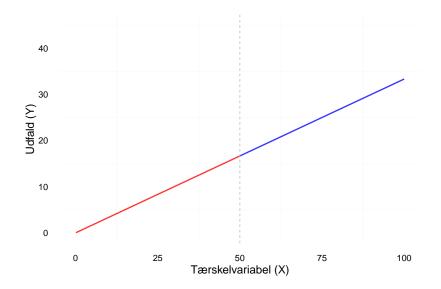
- Stærk intern validitet (Cook og Wong 2008; Dunning 2012; Berk 2010, 574)
- ▶ Mindre ekstern validitet (Imbens og Lemieux 2008, 622)
- Mindre statistisk validitet
 - Lav power

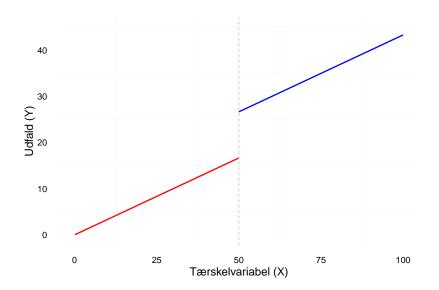
RDD og Rubins kausalmodel

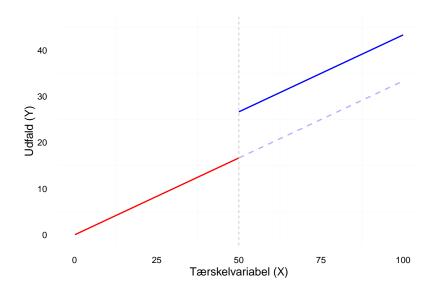
- ▶ For hver observation i har vi et potentielt udfald (Y_i) og en stimulitildeling (W_i)
- ▶ Potentielt udfald givet stimuli: $Y_i(W_i)$
 - Eksempelvis to potentielle udfald $Y_i(1), Y_i(0)$
- ▶ Tærskelvariabel: X_i
- Tærskelværdi: c (diskontinuitet)
- Stimulitildeling:

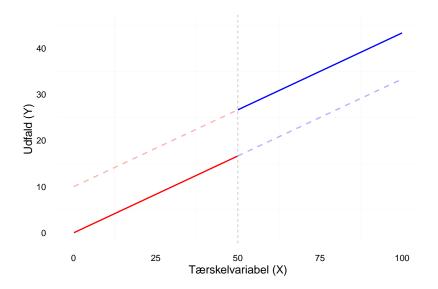
$$W_i = \begin{cases} W_i = 1 & \text{if } X_i \ge c \\ W_i = 0 & \text{if } X_i < c \end{cases}$$

Eksempel med tærskelværdi c = 50









Eksempler på tærskelvariable

- En tærskelvariabel kan eksempelvis være:
 - Stemmeandel
 - Fødselsdato/fødselsår
 - Indkomst
 - Gruppestørrelse
 - Testscore
 - Geografisk distance
- I tilfælde hvor velkendte regler inddeler observationer i grupper, har vi et potentielt RDD
 - Politik er fyldt med regler

Robusthedstests

- Undersøg hvor robuste resultaterne er
 - ► Funktionel form, bandwidth, software defaults
- Kontrolvariable
 - ▶ Kan give mere præcise estimater
 - ► Test som udfaldsvariable
- Placebotests
 - Andre tærskelværdier

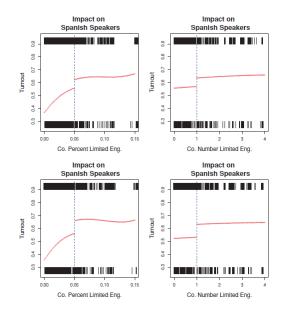
Eksempel: Effekten af stipendier (Thistlethwaite og Campbell 1960)

- ▶ Effekten af stipendier (W_i) på fremtidig akademisk præstation (Y_i)
- ▶ Stipendier gives på baggrund af SAT præstation (X_i)
- ► Stimuli: Dem der med nød og næppe har modtaget stipendium
- Kontrol: Dem der med nød og næppe ikke har modtaget stipendium

Eksempel: Spansksprogede stemmesedler

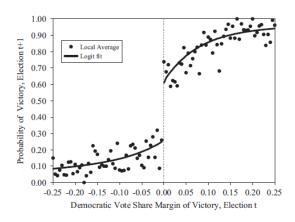
- ► Hopkins (2011): Translating into Votes: The Electoral Impacts of Spanish-Language Ballots
- ► Tærskelværdi (c): Steder emd en sprogminoritet på over +10,000 borgere skal give en spansk stemmeseddel (Voting Rights Act)
- ► Tærskelvariabel (X): Populationstørrelse
- ▶ Udfaldsvariabel (Y): Valgdeltagelse (%)

Eksempel: Spansksprogede stemmesedler



Eksempel: Incumbency bonus

► Lee (2008): Randomized experiments from non-random selection in U.S. House elections

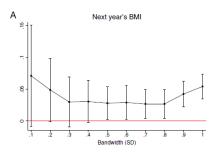


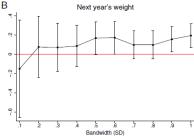
Eksempel: Validiteten af tætte valg og RDD

- ▶ Flere studier diskuterer validiteten af tætte valg og RDD
 - ▶ Grimmer et al. (2011): Gubernatorial and State House control is correlated with winning close elections for the U.S. House
 - Caughey og Sekhon (2011): Covariate imbalances between near winners and losers.
 - Eggers et al. (2015): No systematic evidence of sorting or imbalance around electoral thresholds.
 - ▶ Hainmueller et al. (2015) og de la Cuesta og Imai (2016).

Eksempel: Effekten af at blive kaldt overvægtig (Almond et al. 2016)

"We compare those narrowly designated as overweight to those narrowly designated as having a healthy BMI. For students who were particularly close to the overweight threshold, overweight categorization has an arbitrary component because individual control over small movements in the recorded BMI is imperfect."





Instrumentelle variable (IV)

- ► En instrumentel variabel forklarer stimulitildeling (som en tærskelvariabel i RDD)
 - "An instrument is a variable thought to randomly induce variation in the treatment variable of interest." (Gelman og Hill 2007, 216)
- IV kræver stærke antagelser
 - I observationsstudier/naturlige eksperimenter er disse ofte urealistiske
- Lokal gennemsnitlig stimulieffekt (LATE)
- ▶ Intro: Hairi (2014): Statskundskabens sammenfiltrede virkelighed og et bud på en løsning: IV-estimation

IV: Løsningen på hvad?

- ► Kan bruges både i eksperimenter og observationsstudier
 - Estimation af stimulieffekter i eksperimenter for dem der overholder stimulitildelelse
- ▶ IV skaber *eksogen* variation i stimulitildelingen
- "The solution offered by the instrumental-variables design is to find an additional variable - an instrument - that is correlated with the independent variable but could not be influenced by the dependent variable or correlated with its other causes." (Dunning 2012, 87)

Eksempel: Tildelelse af førtidspension

▶ Bengtsson et al. (2014): "Vi finder et naturligt eksperiment, hvor alle andre faktorer er holdt konstante. Det gør vi ved at finde et forhold, som er afgørende for, om flere får en pension, men som ikke har noget med den enkelte borger at gøre. I vores undersøgelsesdesign udnytter vi det element af tilfældighed, om borgeren bor i en"pensions" eller "ikke-pensions" kommune. Det anser vi for at være tilfældigt set i forhold til borgeren, og det anvender vi som en slags instrument til at variere vores årsagsfaktor, altså om borgere får tilkendt førtidspension."

Eksempel: Klassestørrelse og testresultater

- Randomiseringen i forhold til om man kommer i en lille eller stor klase
- Krueger (1999): "initial random assignment is used as an instrumental variable for actual class size." (p. 507)
- "It is possible that some students were switched from their randomly assigned class to another class before school started or early in the fall." (p. 502)

Eksempel: Klassestørrelse og testresultater

TABLE VII

OLS AND 2SLS ESTIMATES OF EFFECT OF CLASS SIZE ON ACHIEVEMENT

DEPENDENT VARIABLE: AVERAGE PERCENTILE SCORE ON SAT

Grade	OLS	2SLS	Sample size
	(1)	(2)	(3)
K	62	71	5,861
	(.14)	(.14)	
1	85	88	6,452
	(.13)	(.16)	
2	59	67	5,950
	(.12)	(.14)	
3	61	81	6,109
	(.13)	(.15)	

The coefficient on the actual number of students in each class is reported. All models also control for school effects; student's race, gender, and free lunch status; teacher race, experience, and education. Robust standard errors that allow for correlated errors among students in the same class are reported in parentheses.

Eksempel: Klassestørrelse og testresultater

Specifically, we estimate the following model by 2SLS:

(3)
$$CS_{ics} = \pi_0 + \pi_1 S_{ios} + \pi_2 R_{ios} + \pi_3 X_{ics} + \delta_s + \tau_{ics}$$

(4)
$$Y_{ics} = \beta_0 + \beta_1 C S_{ics} + \beta_2 X_{ics} + \alpha_s + \epsilon_{ics},$$

where CS_{ics} is the actual number of students in the class, S_{ios} is a dummy variable indicating assignment to a small class the first year the student is observed in the experiment, R_{ios} is a dummy variable indicating assignment to a regular class the first year the student is observed in the experiment, and all other variables are defined as before. Again, the error term (ϵ_{ics}) is treated as consisting of a common class effect and an idiosyncratic individual effect, and the standard errors are adjusted for correlation in the residuals among students in the same class.

In this setup, only variation in class size due to *initial* assignment to a regular or small class is used to provide variation in actual class size in the test score equation. Due to the random assignment of initial class type, one would expect that this excluded instrumental variable is uncorrelated with $\epsilon_{\textit{ics}}$, as required for 2SLS to be consistent.

IV-regression

- ► To trin
 - Første trin: $D_i = \alpha_0 + \alpha_1 W_i + v_i$
 - Andet trin: $Y_i = \beta_0 + \beta_1 D_i + \epsilon_i$
- ▶ Den kausale effekt af D på Y er β_1
- Vigtigt: Vi skal tage højde for usikkerhed i begge trin!

Eksempel: Militærtjeneste og indkomst

- ▶ Angrist (1990): The Vietnam Draft Lottery
- ▶ Udfald (Y): Indkomst
- Stimuli (D): Krigsveteran
- Hvorfor ikke bare undersøge gennemsnitsforskelle mellem veteraner og ikke-veteraner?
 - ▶ Ikke tilfældigt
- The draft lottery facilitates estimation of (1) because functions of randomly assigned lottery numbers provide instrumental variables that are correlated with s_i , but orthogonal to the error term, u_{ir} ." (p. 319)

Eksempel: Militærtjeneste og indkomst

TABLE 3-WALD ESTIMATES

		Draft-E	igibility Effects in				
Cohort	Year	FICA Earnings (1)	Adjusted FICA Earnings (2)	Total W-2 Earnings (3)	$\hat{p}^e - \hat{p}^n$ (4)	Service Effect in 1978 \$ (5)	
1950	1981	-435.8	- 487.8	- 589.6	0.159	-2,195.8	
		(210.5)	(237.6)	(299.4)	(0.040)	(1,069.5)	
	1982	-320.2	-396.1	- 305.5	` '	-1,678.3	
		(235.8)	(281.7)	(345.4)		(1,193.6)	
	1983	-349.5	-450.1	-512.9		-1,795.6	
		(261.6)	(302.0)	(441.2)		(1,204.8)	
	1984	-484.3	-638.7	-1,143.3		-2,517.7	
		(286.8)	(336.5)	(492.2)		(1,326.5)	
1951	1981	-358.3	-428.7	-71.6	0.136	-2,261.3	
		(203.6)	(224.5)	(423.4)	(0.043)	(1,184.2)	
	1982	-117.3	-278.5	-72.7		-1,386.6	
		(229.1)	(264.1)	(372.1)		(1,312.1)	
	1983	-314.0	-452.2	- 896.5		-2,181.8	
		(253.2)	(289.2)	(426.3)		(1,395.3)	
	1984	-398.4	- 573.3	-809.1		- 2,647.9	
		(279.2)	(331.1)	(380.9)		(1,529.2)	
1952	1981	-342.8	-392.6	- 44 0.5	0.105	-2,502.3	
		(206.8)	(228.6)	(265.0)	(0.050)	(1,556.7)	
	1982	-235.1	- 255.2	-514.7		-1,626.5	
		(232.3)	(264.5)	(296.5)		(1,685.8)	
	1983	-437.7	- 500.0	-915.7		-3,103.5	
		(257.5)	(294.7)	(395.2)		(1,829.2)	
	1984	-436.0	- 560.0	- 767.2		-3,323.8	
		(281.9)	(330.1)	(376.0)		(1,959.3)	

Eksempel: Politi og kriminalitet

- ▶ Levitt (1997): The effect of increased police force on crime
- "Cities with high crime rates, therefore, may tend to have large police forces, even if police reduce crime." (p. 270)
- Instrument: Valg
- "In order to identify the effect of police on crime, a variable is required that affects the size of the police force, but does not belong directly in the crime" production function. "The instrument employed in this paper is the timing of mayoral and gubernatorial elections." (p. 271)

Eksempel: Politi og kriminalitet

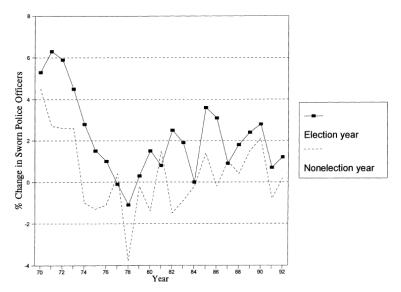


FIGURE 2. YEARLY CHANGES IN SWORN POLICE (ELECTION YEARS VERSUS NONELECTION YEARS)

Eksempel: Politi og kriminalitet

TABLE 5-CRIME-SPECIFIC ESTIMATES OF THE EFFECT OF CHANGES IN SWORN OFFICERS

	Murder	Rape	Robbery	Assault	Burglary	Larceny	Motor vehicle theft
OLS (levels)	0.27	-0.07	0.64	0.34	0.08	0.14	0.38
	(0.06)	(0.05)	(0.05)	(0.06)	(0.05)	(0.05)	(0.06)
OLS (differences)	-0.60 (0.19)	-0.06 (0.13)	-0.31 (0.10)	0.11 (0.13)	-0.25 (0.08)	-0.10 (0.06)	-0.29 (0.10)
2SLS (elections as instruments)	-3.05 (0.91)	0.67 (1.22)	-1.20 (1.31)	-0.82 (1.20)	-0.58 (1.55)	0.26 (1.66)	-0.61 (1.31)
2SLS (election*city-size interactions as instruments)	-2.09	0.08	-0.38	-0.36	-0.39	0.06	0.14
	(0.64)	(0.84)	(0.89)	(0.81)	(1.06)	(1.20)	(0.89)
2SLS (election*region interactions as instruments)	-1.18	-0.11	-0.49	-0.41	-0.11	-0.21	-0.34
	(0.39)	(0.49)	(0.53)	(0.50)	(0.62)	(0.67)	(0.53)
LIML (election*region interactions as instruments)	-1.98	-0.27	-0.79	-1.09	-0.05	-0.43	-0.50
	(0.59)	(0.77)	(0.79)	(0.73)	(0.90)	(1.01)	(0.80)

Hvad er et godt instrument?

- ► Det bedste instrument er et randomiseret stimuli i et eksperiment
- I naturlige eksperimenter kræver det teori (viden om stimulitildelingsmekanismen)
- ▶ "The most important potential problem is a bad instrument, that is, an instrument that is correlated with the omitted variables (or the error term in the structural equation of interest in the case of simultaneous equations)." (Angrist og Krueger 2001, 79)

Tjekliste (Sovey og Green 2011, 198)

- Model
 - Hvad vil vi gerne estimere?
- Uafhængighed
 - Hvorfor er IV uafhængigt af andre forklaringer til variation i den afhængige variabel?
- Udelukkelsesbegrænsning
 - Hvorfor har instrumentet ingen direkte effekt på den afhængige variabel?
- Instrumentstyrke
 - Hvor stærkt er instrumentet?
- Monotonicitet
 - ► Er det plausibelt, at der ikke er *defiers*?
- SUTVA

Udvalgte praktiske råd i IV-analyser (Hairi 2014)

- ► Rapporter altid F-teststørrelsen i analysens første trin
- Medtag de samme kontrolvariable i første og andet trin
- Brug ikke endogene kontrolvariable
- Pas på med laggede instrumenter
- An instrument does not a theory make
- Brug gerne IV-estimation som et supplement til OLS

Difference-in-difference

- ▶ DID kombinerer før og efter-måling med stimuli og kontrol
 - ▶ To grupper med to perioder
- Eksempel:
 - Design A har en før og efter måling
 - Design B har en stimuli- og kontrolgruppe
 - ▶ Design A + Design B = DID
- DID estimator
 - $[\bar{Y}_1|T \bar{Y}_0|T] [\bar{Y}_1|C \bar{Y}_0|C]$
- ▶ Kaldes også for multiple time series design

Difference-in-difference

- Ideelt til at estimere effekten af en politik
- ▶ DID udnytter tidsmæssig variation, men fordrer (også) fundamentale antagelser
 - Kontrolgruppen er et godt kontrafaktisk scenarie da det oplever samme tidsmæssige udvikling med undtagegelse af stimuli
 - Antagelsen om parallel tendens (i fravær afstimuli)
 - Antagelsen om det kontrafaktiske scenarie

Robusthedstests

- Forskellige måder at teste robustheden af ens DID
 - 1. Placebotests i tid
 - Undersøg tidligere perioder
 - 2. Placebotests i rum
 - Undersøg andre kontrolgrupper
 - Placebotests i udfald
 - Undersøg andre uafhængige variable
 - ▶ Gerne nogle som stimuli på ingen måde skulle kunne ændre
- Robusthedstests i DID kan give DIDID (difference-in-difference-in-difference)
 - Placebotesten giver endnu en forskelsestimator

Eksempel: Kommunestørrelse og political efficacy

- Har kommunestørrelsen nogen betydning for vælgernes opfattelse af politik?
- Lassen og Serritzlew (2011) undersøger effekten af kommunesammenlægningen på vælgernes internal political efficacy (IPE)
- ► DID fordi:
 - ▶ Pre- og post-målinger
 - ▶ Nogle, men ikke alle kommuner, blev påvirket af reformen

Eksempel: Kommunestørrelse og political efficacy

TABLE 3. Effect of Municipal Amalgamation and Size on Political Efficacy: Evidence from Difference-in-Difference Analysis

	IPE- Complex	IPE- Niemi
Model 1: Binary treatment		
Amalgamated municipality	-0.36	-0.48
. ,	[0.23]*	[0.24]*
Model 2: Categorical treatment		
Small-Small	-0.43	-0.84
	[0.23]*	[0.28]***
Small-Large	-0.23	-0.43
•	[0.27]	[0.29]
Large-Small	-0.44	-0.31
	[0.23]*	[0.38]
Large-Large	-0.35	-0.34
	[0.25]	[0.40]
Model 3: Absolute population	-0.08	-0.09
difference	[0.04]**	[0.05]*
Model 4: Relative population	-0.04	-0.08
difference	[0.02]*	[0.03]***
N	2,028	2,028

^{*}Significant at 10%; ** significant at 5%; *** significant at 1%.

Eksempel: Offentlige politikker og vælgernes holdninger

- ► Flere studier undersøger effekten af offentlige politikker på vælgerens holdninger vha. DID
- Watson (2015): Effekten af velfærdspolitikker i England på demokratisk deltagelse
- ▶ Pacheco (2013): Effekten af rygeforbud i USA på holdninger til:
 - rygere
 - passiv rygning
 - antirygningspolitikker

RDD, IV og DID i praksis

- ▶ Både RDD, IV og DID kan analyseres i R såvel som Stata
 - ▶ DID kan i den simpleste form forstås som en tovejsinteraktion
- Har I data, der skal analyseres: kontakt mig

Dagens øvelse

- Overvej hvilken eksogen/tilfældig variation, der vil være ideel til at undersøge dit/jeres forskningsspørgsmål
- Hvad er den største udfordring?
 - ► Manglende data?
 - Svært at forestille sig eksistensen af en sådan tilfældig variation?

Næste gang

- Observationsdata, part I
- ► Mandag, kl. 10-12 i U31A